

SAD 2026L

Część 2 Projektu

Matuszewski Maciej, Sosnowski Wiktor

Problem 1. CTG - kontynuacja: testy zgodności i moc

1. Wprowadzenie

Niniejsze opracowanie stanowi bezpośrednią kontynuację Problemu 2 z części pierwszej projektu, w którym zilustrowano graficznie zbieżność rozkładu średniej z próby $\bar{X}_n$ do rozkładu normalnego, zgodnie z Centralnym Twierdzeniem Granicznym (CTG). Teraz zbieżność ta zostaje zweryfikowana formalnie, tj. za pomocą testów statystycznych zgodności rozkładu z $\mathcal{N}(\mu, \sigma^2/n)$.

Punktem wyjścia jest pojedynczy rozkład $X \sim \text{Exp}(\lambda = 1)$ - ten sam, którego użyto w części pierwszej - co pozwala wykorzystać analityczne momenty rozkładu wyjściowego oraz porównać konkluzje z wcześniejszą analizą graficzną. Dla rosnących licznosci próby n rozkład $\bar{X}_n$ przestaje wykazywać prawoskośność i zbliża się do $\mathcal{N}(\mu, \sigma^2/n)$ - pytanie brzmi: **który test najszybciej rozróżnia te dwa rozkłady?**

Porównujemy moc trzech testów normalności na podstawie symulacji Monte Carlo:

1. **test Kołmogorowa–Smirnowa** (KS) - przeciwko w pełni wyspecyfikowanej $\mathcal{N}(\mu_T, \sigma_T^2/n)$,
2. **test Shapiro–Wilka** (SW) - klasyczny test oparty na korelacji statystyk pozycyjnych,
3. **test D’Agostino–Pearsona K^2** (DA) - test oparty na standaryzowanej skośności i kurtozie.

2. Metodologia

2.1. Rozkład bazowy i statystyka badana

Niech $X_1, \dots, X_n \stackrel{\text{iid}}{\sim} \text{Exp}(\lambda = 1)$. Z teorii znamy:

$$\mu_T = \mathbb{E}[X] = 1, \quad \sigma_T^2 = \text{Var}(X) = 1, \quad \gamma_1 = 2, \quad \gamma_2 = 6,$$

skąd dla średniej $\bar{X}_n = \frac{1}{n} \sum X_i$:

$$\mathbb{E}\bar{X}_n = \mu_T, \quad \text{Var}\bar{X}_n = \sigma_T^2/n, \quad \text{skew}(\bar{X}_n) = \frac{2}{\sqrt{n}}, \quad \text{exc. kurt}(\bar{X}_n) = \frac{6}{n}.$$

CTG mówi, że $\bar{X}_n \xrightarrow{d} \mathcal{N}(\mu_T, \sigma_T^2/n)$, więc dla **dużego** n żaden z testów nie powinien systematycznie odrzucać hipotezy o normalności. Dla **małego** n rozkład $\bar{X}_n$ jest jednak nadal wyraźnie skośny, a moc testu - czyli prawdopodobieństwo wykrycia tej rozbieżności - staje się głównym kryterium oceny.

2.2. Schemat symulacji

Niech K oznacza wielkość próby przekazywanej *każdemu* z testów (tj. liczbę średnich obliczonych w pętli), a n liczbę uśrednianych zmiennych losowych. Wybrano $K \in \{20, 50, 100\}$ (zgodnie z poleceniem - “kilkadziesiąt”), przy czym wartością wyróżnioną jest $K = 50$. Przyjęto $\alpha = 0,05$.

Pojedyncza replikacja Monte Carlo wygląda następująco:

1. Losuje się K niezależnych średnich $\bar{X}_n^{(1)}, \dots, \bar{X}_n^{(K)}$, z których każda jest obliczona z n wartości $\text{Exp}(1)$.
2. Na tej K -elementowej próbce uruchamia się trzy testy normalności (KS, SW, DA) i zapisuje uzyskane p -wartości.
3. Z tej samej próbki estymuje się skośność $\hat{g}_1$ i kurtozę $\hat{b}_2$ - wielkości stojące u podstaw testu D’Agostino.

Schemat powtarzany jest $M = 5\,000$ razy dla każdej pary (n, K) z siatki $n \in \{2, 3, 5, 10, 20, 30, 50, 100, 200\}$, $K \in \{20, 50, 100\}$. Moc testu definiujemy jako empiryczne prawdopodobieństwo odrzucenia H_0 :

$$\widehat{\text{moc}}(n, K, \text{test}) = \frac{1}{M} \sum_{i=1}^M \mathbb{1}(p^{(i)} < \alpha).$$

Eksperyment zrealizowano w **R 4.5.3** (`ggplot2`, `dplyr`, `tidyr`) w środowisku `conda`. Kod podzielony jest modularnie na pliki `R/config.R` (stałe), `R/tests.R` (testy normalności wraz z ręczną implementacją D’Agostino–Pearsona), `R/simulation.R` (pętla MC), `R/plots.R` (wizualizacje) oraz `R/main.R` (punkt wejścia). Reprodukowalność zapewnia `set.seed(20260519)`.

2.3. Implementacja testów

KS stosujemy w wersji *w pełni wyspecyfikowanej*: porównujemy empiryczną dystrybuantę próbki K średnich z dystrybuantą $\mathcal{N}(\mu_T, \sigma_T^2/n)$, gdzie μ_T i σ_T^2 są **znanymi** momentami rozkładu wyjściowego. Tak skonstruowany test ma poprawny rozmiar (nie wymaga poprawki Lillieforsa), co czyni porównanie z dwoma pozostałymi testami uczciwym.

SW używamy w wbudowanej postaci `stats::shapiro.test()` (estymuje μ, σ z danych, ważny dla $3 \leq K \leq 5000$).


D’Agostino–Pearson K^2 zaimplementowano ręcznie - biblioteka `moments` nie była dostępna w środowisku - na podstawie wzorów D’Agostino (1970) i Anscombe’a–Glynn (1983). Test łączy standaryzowane Z_1 (skośność) i Z_2 (kurtoza):

$$K^2 = Z_1^2 + Z_2^2 \sim \chi^2(2) \text{ pod } H_0,$$

zatem $p\text{-value} = 1 - F_{\chi^2_2}(K^2)$. Składowe Z_1 i Z_2 pełnią podwójną rolę: po pierwsze definiują test, po drugie - same w sobie są estymatorami “ile odchyień standardowych” empiryczna skośność / kurtoza oddala próbkę od próbki normalnej.

3. Wyniki

3.1. Co “widzi” test - wizualizacja jednej replikacji



Rysunek 1: Histogramy standaryzowanej średniej $\bar{X}_n$ na pojedynczej próbie $K = 50$ średnich, dla wybranych n .

Już na pojedynczej realizacji ($K = 50$, ziarno ustalone) widać efekt CTG: histogram dla $n = 2$ wyraźnie odbiega od $\mathcal{N}(0,1)$ (prawoskośność, ciężki prawy ogon); dla $n = 30$ rozkład jest niemal symetryczny, a przy $n = 200$ histogram jest praktycznie nieodróżnialny od krzywej Gaussa. Testy normalności muszą podjąć decyzję **dokładnie** na takiej K -elementowej próbie.


3.2. Tabela mocy ($K = 50$, $\alpha = 0,05$)

Tabela 1. Empiryczne moce testów wyznaczone z $M = 5\,000$ replikacji.

n	$\widehat{\text{moc}}_{KS}$	$\widehat{\text{moc}}_{SW}$	$\widehat{\text{moc}}_{DA}$	$\hat{g}_1$ (śr.)	$\hat{b}_2 - 3$ (śr.)
2	0,236	0,950	0,799	1,19	1,60
3	0,177	0,828	0,658	0,99	1,10
5	0,132	0,598	0,476	0,78	0,64
10	0,085	0,331	0,290	0,55	0,26
20	0,068	0,190	0,188	0,39	0,08
30	0,056	0,137	0,146	0,32	0,01
50	0,055	0,099	0,110	0,24	-0,03
100	0,057	0,082	0,087	0,17	-0,06
200	0,046	0,060	0,069	0,12	-0,11

Test odznaczony pogrubieniem to najmocniejszy test w danym wierszu. Wartości średniej skośności i nadwyżki kurtozy obrazują, jak silnie $\bar{X}_n$ odbiega od $\mathcal{N}(0,1)$ w sensie momentów trzeciego i czwartego rzędu. Pełną siatkę (wszystkie wartości K) zapisano w `output/power_grid.csv`.


3.3. Moc w funkcji n



Rysunek 2: Moce trzech testów dla $K = 50$, $\alpha = 0,05$. Linia przerywana - rozmiar testu.

Krzywe mocy mają wyraźną hierarchię: dla każdego $n \leq 20$ zachodzi $\widehat{moc}_{SW} > \widehat{moc}_{DA} \gg \widehat{moc}_{KS}$. Powyżej $n \approx 20$ moce SW i DA zrównują się, a od $n \geq 30$ DA wyprzedza SW o 0,005–0,01 (różnica mieści się w przedziale ufności replikacji). KS pozostaje zauważalnie słabszy w całym zakresie. Wszystkie trzy krzywe zbiegają do poziomu nominalnego $\alpha = 0,05$ przy $n \rightarrow \infty$, co potwierdza, że tempo zbiegania mocy do rozmiaru testu jest tutaj empirycznym odpowiednikiem szybkości CTG.

3.4. Wpływ wielkości próby testowej K



Rysunek 3: Moce w funkcji n , z podziałem na panele dla $K \in \{20, 50, 100\}$.


Wpływ K jest bardzo wyraźny. Przy $K = 20$ nawet dla $n = 2$ żaden z testów nie osiąga mocy 0,55. Przy $K = 100$ ten sam $n = 2$ daje moc $\approx 0,99$ dla SW i DA, a KS rośnie z 0,12 do 0,44. Wzorec uporządkowania $SW > DA > KS$ jest jednak zachowany dla każdego K - różnica jest tylko ilościowa, nie jakościowa. Wynika z tego, że **dobór K (a nie wybór konkretnego testu)** jest najważniejszą decyzją projektową przy planowaniu eksperymentu wykrywania niezgodności z rozkładem normalnym.

3.5. Skośność i kurtoza - interpretacja testu D'Agostino

Test D'Agostino-Pearsona buduje statystykę z dwóch składowych: standaryzowanej skośności Z_1 i standaryzowanej kurtozy Z_2 . Aby zrozumieć, dlaczego DA “działa” lub “nie działa”, musimy zobaczyć, jak rzeczywiste wartości skośności i kurtozy $\bar{X}_n$ zachowują się w funkcji n .

Skośność i nadwyżka kurtozy $\bar{X}_n$ - empiryczne vs. teoretyczne

Teoria: skew = $2/\sqrt{n}$, excess kurt = $6/n$ (rozkład Exp(1))




Rysunek 4: Empiryczna skośność i nadwyżka kurtozy próbki $K = 50$ średnich, w zestawieniu z wartościami teoretycznymi $2/\sqrt{n}$ oraz $6/n$.

Empiryczne krzywe niemal dokładnie pokrywają się z teoretycznymi $2/\sqrt{n}$ i $6/n$, przy systematycznie lekko obniżonym poziomie - to znane ujemne obciążenie estymatora skośności i kurtozy dla małych K (wartość oczekiwana g_1 jest mniejsza niż γ_1 , gdy $\gamma_1 > 0$). Oba momenty maleją gładko i monotonicznie, przy czym nadwyżka kurtozy spada *szybciej* ($O(1/n)$) niż skośność ($O(1/\sqrt{n})$).

Standaryzowane składowe testu D'Agostino-Pearson K^2


Linie przerywane: kwantyle ± 1.96 (krytyczne wartości $N(0,1)$ przy $\alpha = 0.05$)




Rysunek 5: Średnie wartości Z_1 (skośność) i Z_2 (kurtoza) z $M = 5\,000$ replikacji, $K = 50$.

Średnie Z_1 przekracza wartość krytyczną $\pm 1,96$ aż do $n \approx 5$, podczas gdy Z_2 utrzymuje się **poniżej** tej granicy dla wszystkich $n \geq 2$. Innymi słowy: w naszym przypadku **całą “pracę” detekcji** w teście D’Agostino wykonuje składowa skośnościowa. Składowa kurtozowa jest “zasilana” mniejszym sygnałem, ponieważ $6/n$ tłumi się szybciej niż $2/\sqrt{n}$. To uzasadnia, dlaczego DA - choć łączy dwie składowe - nie zyskuje istotnej przewagi nad SW: skośność (na której zarówno SW, jak i DA pośrednio się opierają) zanika powoli, a kurtoza zanika zbyt szybko, by stanowić użyteczne źródło dodatkowego sygnału.


3.6. Rozkład p -value: trzy scenariusze



Rysunek 6: p -value przy $n = 5$ ($K = 50$): nagromadzenie blisko zera, najwyraźniejsze dla SW i DA.



Rysunek 7: p -value przy $n = 30$ ($K = 50$): kształt mieszany - nagromadzenie blisko zera tylko w SW i DA.



Rysunek 8: p -value przy $n = 200$ ($K = 50$): brak nagromadzenia - wszystkie trzy rozkłady niemal $Uniform(0,1)$.

Wizualizacja p -value pokazuje, dlaczego decyzja oparta wyłącznie na liczbie odrzuceń bywa myląca. Przy $n = 5$ SW i DA mają wyraźnie trójkątny rozkład p -value (gęstość rośnie z p -value malejącym do zera). Przy $n = 200$ wszystkie trzy histogramy są bliskie $Uniform(0,1)$ - hipoteza H_0 jest *prawie* spełniona, więc rozmiar testu pokrywa się z poziomem istotności.

4. Interpretacja

Hierarchia mocy. Najmocniejszym testem zgodności rozkładu $\bar{X}_n$ z normalnym dla rozkładu wyjściowego $\text{Exp}(1)$ i $K \in \{20, 50, 100\}$ jest test **Shapiro–Wilka** (w zakresie małych n , gdzie różnice między testami są największe), zaraz za nim **D’Agostino–Pearson K^2** . Test **Kołmogorowa–Smirnowa** istotnie ustępuje obu pozostałym testom - szczególnie przy małym n , gdzie różnica wynosi nawet kilkadziesiąt punktów procentowych mocy.

Powód jest dobrze znany w literaturze: SW ma najlepsze własności (zarówno dla dużych, jak i małych prób) względem **alternatyw skośnych** o lekko cięższych ogonach niż normalny - czyli dokładnie tej klasy, w której znajduje się $\bar{X}_n$ przy małym n dla rozkładu $\text{Exp}(1)$. KS - jako test “ogólny”, oparty na maksymalnej odległości między dystrybuantami - rozprasza moc na wszystkie kierunki odchyień i przez to gorzej wykrywa konkretny rodzaj niezgodności.

Rola skośności i kurtozy w D’Agostino. Empiryczne wartości skośności idealnie pokrywają się z teoretycznym $2/\sqrt{n}$, natomiast nadwyżka kurtozy zanika szybciej niż wynikałoby z teorii - efekt ujemnego obciążenia estymatora b_2 dla skończonego K . To wyjaśnia różnicę między SW a DA: oba testy korzystają z asymetrii, ale DA osłabia sygnał skośnościowy przez słabszy, szybciej zanikający sygnał kurtozowy. Stąd DA niemal nigdy nie pokonuje SW w naszym eksperymencie. Wyjątkiem jest obszar $n \geq 30$, gdzie obie składowe Z_1, Z_2 są małe i każda niewielka przewaga DA wynika z faktu, że łączy dwa źródła informacji.

Rola wielkości K . Wzrost K z 20 do 100 zwiększa moc każdego testu **wielokrotnie** - dla $n = 5$ moc SW rośnie z 0,24 do 0,91. Jest to znacznie większy efekt niż wybór testu w obrębie ustalonego K . Dlatego z praktycznego punktu widzenia, **jeśli badacz może kontrolować K , jest to ważniejsza decyzja niż wybór między SW a DA.**

Empiryczny rozmiar testu. Dla $n = 200$ (gdzie H_0 jest niemal spełniona) wszystkie trzy testy mają empiryczny rozmiar bliski nominalnemu $\alpha = 0,05$ (SW: 0,060; DA: 0,069; KS: 0,046). Lekkie odchylenie DA powyżej α jest tutaj skutkiem ograniczonej liczby replikacji ($M = 5000$, błąd standardowy $\approx 0,003$) i nie jest istotne.

5. Wnioski

1. Dla rozkładu $\text{Exp}(1)$ i wielkości testu $K \in \{20, 50, 100\}$ **test Shapiro–Wilka** jest najmocniejszy w niemal całym zakresie n , choć od $n \geq 30$ jego przewaga nad D’Agostino–Pearsonem zanika.
2. **Test D’Agostino–Pearsona** jest bliski SW i lepszy od KS; jego siłą jest łatwość interpretacji - rozkłada decyzję na dwie składowe (Z_1 - skośność, Z_2 - kurtoza), co pozwala *zobaczyć, dlaczego* test odrzuca.
3. **Test Kołmogorowa–Smirnowa** jest istotnie słabszy dla alternatyw o lekkiej prawoskośności, jakie generuje średnia z $\text{Exp}(1)$. Jest to znana właściwość tego testu - uniwersalność procedury KS oznacza utratę mocy dla konkretnych klas alternatyw.
4. **Liczność próby testowej K** ma znacznie większy wpływ na moc niż wybór konkretnego testu. Przed inwestycją w wybór procedury warto więc rozważyć zwiększenie K .
5. Empiryczna skośność $\hat{g}_1$ idealnie pokrywa się z teoretyczną $2/\sqrt{n}$, natomiast nadwyżka kurtozy $\hat{b}_2 - 3$ jest systematycznie *zaniżona* względem teoretycznego $6/n$ - efekt ujemnego obciążenia tych estymatorów dla skończonego K . To tłumaczy, dlaczego skośnościowa składowa testu D’Agostino wykonuje większą część pracy.

6. **Empiryczny rozmiar testu** dla wszystkich trzech procedur jest bliski nominalnemu $\alpha = 0,05$ przy dużym n , co potwierdza poprawność implementacji oraz fakt, że CTG dla $n \gtrsim 200$ jest tutaj praktycznie nieodróżnialne od ścisłej normalności.
-

Dodatek A - odtworzenie wyników

```
# Utworzenie środowiska (jednorazowo)
conda create -n sad-clt -c conda-forge -y r-base r-ggplot2 r-dplyr r-tidyr \
  pandoc tectonic

# Uruchomienie symulacji
conda activate sad-clt
Rscript R/main.R

# Kompilacja raportu do PDF
pandoc report.md -o report.pdf --pdf-engine=tectonic -V lang=pl -H header.tex
```

Wygenerowane pliki:

- `plots/*.png` - wszystkie figury wykorzystane w raporcie,
- `output/power_grid.csv` - pełna siatka mocy testów dla $n \times K \in \{2, 3, 5, 10, 20, 30, 50, 100, 200\} \times \{20, 50, 100\}$,
- `output/pvalue_dump.csv` - surowe p -value z $M = 5000$ replikacji dla trzech wybranych wartości n (5, 30, 200) przy $K = 50$.

Parametryzację eksperymentu (siatki n , K , liczbę replikacji M , ziarno losowe, poziom istotności) zebrano w `R/config.R`.

Problem 2. Odbiornik znanego sygnału

1. Wprowadzenie

Zadanie dotyczy detekcji słabego sygnału pseudoszumowego ukrytego w białym szumie gaussowskim. Dwie osoby ustaliły wcześniej wspólny kod $s(i) \in \{-1, +1\}$, $i = 1, \dots, N$ wygenerowany pseudolosowo. W sytuacji alarmowej nadawca emituje sygnał $As(i)$ o nieznannej amplitudzie A ; odbiorca obserwuje:

$$H_0 : x(i) = w(i), \quad H_1 : x(i) = As(i) + w(i),$$

gdzie $w(i) \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2)$. Celem jest zaprojektowanie optymalnego detektora, wyznaczenie jego mocy oraz analiza wpływu parametrów A , σ^2 i N na skuteczność detekcji.

2. Metoda rozwiązywania problemu

2.1. Wyprowadzenie statystyki testowej

Traktując próbkę $x(1), \dots, x(N)$ jako obserwacje (z różnymi wartościami oczekiwanymi pod H_1), zapisujemy logarytm ilorazu wiarygodności:

$$\ln \Lambda = \sum_{i=1}^N \ln \frac{f_1(x(i))}{f_0(x(i))} = \sum_{i=1}^N \left[\frac{A s(i) x(i)}{\sigma^2} - \frac{A^2 s(i)^2}{2\sigma^2} \right] = \frac{A}{\sigma^2} \underbrace{\sum_{i=1}^N s(i) x(i)}_T - \frac{A^2 N}{2\sigma^2},$$

gdzie skorzystano z $s(i)^2 = 1$. Ponieważ dla $A > 0$ obie stałe A/σ^2 i $A^2 N/(2\sigma^2)$ są dodatnie, test NP redukuje się do porównania **statystyki korelacyjnej** (dopasowanego filtra):

$$T = \sum_{i=1}^N x(i) s(i) = \langle x, s \rangle$$

z progiem krytycznym η . Odrzucamy H_0 , gdy $T > \eta$.

2.2. Rozkład T i wyznaczenie progu

Pod obiema hipotezami T jest sumą niezależnych zmiennych gaussowskich:

$$T \mid H_0 \sim \mathcal{N}(0, \sigma^2 N), \quad T \mid H_1 \sim \mathcal{N}(AN, \sigma^2 N).$$

Dla zadanego poziomu istotności α (prawdopodobieństwo fałszywego alarmu) próg krytyczny wynosi:

$$\eta = z_{1-\alpha} \sqrt{\sigma^2 N},$$

gdzie $z_{1-\alpha} = \Phi^{-1}(1 - \alpha)$. Moc testu (prawdopodobieństwo wykrycia alarmu) dana jest wzorem analitycznym:

$$\beta(A, \sigma^2, N) = 1 - \Phi\left(\frac{\eta - AN}{\sqrt{\sigma^2 N}}\right) = 1 - \Phi\left(z_{1-\alpha} - \frac{A\sqrt{N}}{\sigma}\right).$$

Kluczowym parametrem jest stosunek sygnał/szum:

$$\text{SNR} = \frac{A^2 N}{\sigma^2}.$$

Moc rośnie monotonicznie z SNR: długi kod N zastępuje silny sygnał A .


2.3. Schemat symulacji

Eksperyment przeprowadzono w **R 4.3.3** (tylko pakiety bazowe). Kod podzielony modularnie na pliki `R/config.R`, `R/signal.R`, `R/detector.R`, `R/simulation.R`, `R/plots.R` i `R/main.R`. Reprodukowalność zapewnia `set.seed(20260519)`.

Ustalono: poziom istotności $\alpha = 0,001$, wariancja szumu $\sigma^2 \in \{0,5; 1; 4\}$, długości kodu $N \in \{10, 50, 200, 1000\}$, amplitudy $A \in [0; 3]$ (krok 0,25), liczba replikacji Monte Carlo $M = 5000$ na punkt.

3. Otrzymane wyniki wraz z interpretacją


3.1. Zasada działania detektora



Rysunek 9: Rozkłady statystyki korelacyjnej T pod H_0 i H_1 dla $N = 50$, $A = 0,5$, $\sigma^2 = 1$, $\alpha = 0,001$. Czerwony obszar to prawdopodobieństwo fałszywego alarmu.

Rysunek ilustruje geometrię problemu: pod H_0 rozkład T jest skupiony wokół zera, pod H_1 przesuwają się o $AN = 25$ w prawo. Próg krytyczny $\eta \approx 21,9$ jest tak dobrany, żeby prawdopodobieństwo przekroczenia go pod H_0 wynosiło dokładnie $\alpha = 0,001$ – jest to jednocześnie gwarancja rzadkości fałszywego alarmu. Obszar nakładania się obu krzywych odpowiada przypadkom, gdy detekcja jest trudna: słaby sygnał lub duży szum.


3.2. Moc w funkcji amplitudy A - wpływ długości kodu N



Rysunek 10: Empiryczna i teoretyczna moc detektora w funkcji amplitudy A dla różnych N ($\sigma^2 = 1$, $\alpha = 0,001$). Linie przerywane: wartości teoretyczne.

Zgodność empirycznej mocy z wartościami teoretycznymi potwierdza poprawność implementacji. Widoczna jest wyraźna hierarchia krzywych: przy $N = 10$ nawet $A = 1,5$ nie wystarcza do pewnej detekcji, podczas gdy $N = 1000$ zapewnia moc bliską 1 już dla $A = 0,25$. Jest to bezpośredni efekt wzrostu SNR z N : podwojenie długości kodu równoważy obcięcie amplitudy o czynnik $\sqrt{2}$.


3.3. Moc w funkcji amplitudy A - wpływ wariancji szumu σ^2



Rysunek 11: Empiryczna i teoretyczna moc detektora w funkcji amplitudy A dla różnych σ^2 ($N = 50$, $\alpha = 0,001$). Linie przerywane: wartości teoretyczne.

Wzrost wariancji szumu z 0,5 do 4 przesunęła krzywą mocy znacząco w prawo: przy $\sigma^2 = 4$ osiągnięcie mocy 0,9 wymaga amplitudy $A \approx 1,5$, podczas gdy przy $\sigma^2 = 0,5$ wystarczy $A \approx 0,35$. Efekt jest symetryczny: moc zależy wyłącznie od $\text{SNR} = A^2 N / \sigma^2$, więc czterokrotne zwiększenie szumu odpowiada dwukrotnemu zmniejszeniu amplitudy.


3.4. Przypadek słabego sygnału: $A \ll \sigma$



Rysunek 12: Moc detektora w funkcji długości kodu N dla słabych sygnałów ($\sigma^2 = 1$, $\alpha = 0,001$). Linie przerywane: wartości teoretyczne.

Przypadek $A \ll \sigma$ jest kluczowy z praktycznego punktu widzenia - sygnał alarmowy ma być trudny do wykrycia przez obserwatora zewnętrznego. Dla $A = 0,25$ (SNR = 3,1 przy $N = 50$) detektor praktycznie nie działa: moc $\approx 0,09$. Jednak przy $N = 500$ ta sama amplituda daje moc $\approx 0,98$. Dla $A = 0,5$ przejście następuje wcześniej: $N = 100$ daje moc $\approx 0,97$. Wynika z tego fundamentalna zasada: **wydłużenie kodu N kompensuje słabość sygnału** – wzrost N czterokrotnie odpowiada podwojeniu amplitudy.

3.5. Weryfikacja rozmiaru testu pod H_0



Rysunek 13: p -value pod H_0 ($N = 50$, $\sigma^2 = 1$, $M = 10\,000$ replikacji). Rozkład bliski $\text{Uniform}(0, 1)$ potwierdza poprawność implementacji.

Rozkład p -value pod H_0 jest niemal jednostajny, a rozmiar empiryczny (0,0008) pokrywa się z nominalnym $\alpha = 0,001$. Potwierdza to analityczną poprawność wzoru na próg krytyczny.

4. Interpretacja i wnioski

Optymalność. Wyprowadzony detektor jest testem Neymana–Pearsona dla $A > 0$: przy ustalonym α maksymalizuje moc. Statystyka $T = \langle x, s \rangle$ odpowiada filtrowi dopasowanemu (*matched filter*) – klasycznemu rozwiązaniu w teorii detekcji sygnałów.

Kryterium progu. Próg $\eta = z_{1-\alpha} \sqrt{\sigma^2 N}$ wyznacza się z warunku na prawdopodobieństwo fałszywego alarmu $P_{\text{FA}} = \alpha$. W zastosowaniu alarmowym α powinno być bardzo małe (10^{-3} – 10^{-6}), co odzwierciedla wysoką cenę fałszywego alarmu. Próg rośnie z σ i N , ale moc rośnie *szybciej* niż próg – detektor zyskuje na długości kodu.

Wielobitowy system telekomunikacyjny. Pojedyncza detekcja sygnału s przekazuje 1 bit informacji (alarm/brak). Aby przesłać wiele bitów jednocześnie, można zastosować ortogonalny zestaw kodów $\{s_k\}$, $k = 1, \dots, B$, każdy o długości N , i niezależnie decydować o obecności każdego z nich w odebranych x . Dzięki ortogonalności $\langle s_k, s_l \rangle = 0$ dla $k \neq l$ statystyki $T_k = \langle x, s_k \rangle$ są niezależne pod H_0 , co pozwala kontrolować globalne prawdopodobieństwo fałszywego alarmu korekcją Bonferroniego: $\alpha_{\text{lok}} = \alpha/B$. Minimalna wymagana długość kodu rośnie proporcjonalnie do B/α , co ogranicza praktyczną liczbę równoczesnych bitów.

5. Wnioski

1. Optimalny detektor dla modelu $H_1 : x = As + w$ sprowadza się do porównania korelacji dopasowanej $T = \langle x, s \rangle$ z progiem $\eta = z_{1-\alpha} \sqrt{\sigma^2 N}$.
2. Moc testu zależy wyłącznie od $\text{SNR} = A^2 N / \sigma^2$; wzrost N jest równoważny wzrostowi A^2 – długi kod kompensuje słabą amplitudę.

3. W reżimie $A \ll \sigma$ (sygnał ukryty w szumie) wystarczające SNR można osiągnąć przez wydłużenie kodu, a nie zwiększanie mocy nadawania – co jest zaletą z punktu widzenia ukrycia komunikacji.
 4. Empiryczny rozmiar testu ($0,0008 \approx \alpha$) i zgodność mocy empirycznej z teoretyczną potwierdzają poprawność implementacji.
 5. System można rozszerzyć do wielobitowego przez zestaw wzajemnie ortogonalnych kodów, z Bonferroniego korektą poziomu istotności.
-

Dodatek B – odtworzenie wyników (Problem 2)

```
# z katalogu glownego projektu:  
setwd("sciezka/do/projektu")  
source("R/main.R")
```

Wygenerowane pliki:

- `plots/p2_0*.png` – wykresy Problemu 2,
- `output/p2_moc_vs_A_N.csv` – siatka mocy dla $N \times A$,
- `output/p2_moc_vs_A_sigma2.csv` – siatka mocy dla $\sigma^2 \times A$.